

Classificação de Lesões Cutâneas Utilizando Modelos de Machine Learning e Deep Learning Aplicados ao Dataset HAM10000

Davi Leahy

Afya – UNIMA – Centro Universitário de Maceió
Curso de Ciência da Computação
E-mail: davileahy2@gmail.com

Abstract—Skin cancer is among the most frequent and dangerous types of cancer worldwide, and early detection significantly increases treatment success. This work presents a comparative study between classical machine learning models and a deep learning approach based on ResNet50 for the classification of dermoscopic images from the HAM10000 dataset. The images were grouped into three clinically relevant classes: Benign, Suspicious, and Malignant. Classical models—Support Vector Machine (SVM), Random Forest, and Multilayer Perceptron (MLP)—were trained using handcrafted features, while the deep learning model applied transfer learning with fine-tuning. Results demonstrate that the ResNet50 model significantly outperforms the classical approaches, achieving 0.86 accuracy and robust F1-scores across all classes. The study reinforces the applicability of convolutional neural networks for dermatological diagnostic support.

Index Terms—Skin cancer, Deep Learning, Machine Learning, HAM10000, Computer Vision, ResNet50.

I. INTRODUÇÃO

O câncer de pele constitui uma das enfermidades mais comuns no mundo. A detecção precoce, especialmente no caso do melanoma, aumenta significativamente a taxa de sobrevivência. Com o avanço de técnicas computacionais, modelos baseados em visão computacional têm demonstrado capacidade promissora para auxiliar dermatologistas na triagem de lesões cutâneas.

O objetivo deste trabalho é comparar modelos clássicos de Machine Learning (SVM, Random Forest e MLP) com um modelo de Deep Learning (ResNet50 com *fine-tuning*) aplicado ao dataset HAM10000. O estudo busca avaliar o desempenho de cada abordagem e verificar o impacto do uso de CNNs no diagnóstico assistido.

II. FUNDAMENTAÇÃO TEÓRICA

A. Modelos Clássicos de Machine Learning

1) *Support Vector Machine (SVM)*: O SVM busca maximizar a margem entre hiperplanos que separam as classes. O kernel RBF foi escolhido pela sua capacidade de modelar relações não lineares.

2) *Random Forest*: Modelo baseado em múltiplas árvores de decisão combinadas por votação. Embora robusto, sofre em cenários desbalanceados.

3) *Multilayer Perceptron (MLP)*: Rede neural de camadas densas capaz de modelar padrões complexos, treinada por retropropagação.

B. Redes Neurais Convolucionais

As CNNs são amplamente utilizadas em visão computacional por aprenderem representações hierárquicas. A arquitetura ResNet50 utiliza conexões residuais que facilitam o treinamento de redes profundas e permite excelente generalização.

O uso de *transfer learning* adapta o modelo pré-treinado no ImageNet para a classificação de lesões dermatológicas.

III. METODOLOGIA

A. Dataset

O HAM10000 contém 10.015 imagens dermatoscópicas distribuídas em sete diagnósticos. As classes foram agrupadas conforme:

- **Benigno**: *nv, df, vasc*
- **Suspeito**: *bkl*
- **Maligno**: *mel, bcc, akiec*

A divisão utilizada foi: 70% treino, 15% validação e 15% teste.

B. Pré-processamento

1) *Modelos clássicos*: As imagens foram redimensionadas para 128×128 e extraímos HOG, LBP e histogramas HSV.

2) *CNN*: Para a ResNet50, aplicamos:

- Pré-processamento padrão ImageNet
- Data augmentation (rotações, zoom, flips)
- Normalização min-max

C. Configurações dos Modelos

1) *SVM*: Kernel RBF, C=2, gamma=scale.

2) *Random Forest*: 300 árvores, *class_weight=balanced*.

3) *MLP*: Camadas ocultas (256,128), *early stopping*, taxa de aprendizado adaptativa.

D. Deep Learning (ResNet50)

Treinamento em duas etapas:

- 1) Treinamento da cabeça da rede (base congelada), LR = $1e-4$
- 2) Fine-tuning das últimas camadas convolucionais, LR = $1e-5$

Utilizamos otimizador Adam, *early stopping* e *class weighting*.

IV. PROPOSTA E IMPLEMENTAÇÃO

O sistema foi desenvolvido em Python utilizando TensorFlow, Keras e scikit-learn. O pipeline incluiu organização do dataset, extração de atributos para os modelos clássicos e criação de geradores de imagens para a CNN.

O objetivo da implementação é comparar o desempenho entre abordagens clássicas e modernas, demonstrando o impacto do *transfer learning* em visão computacional médica.

V. RESULTADOS

A. Modelos Clássicos

Os resultados mostram que modelos clássicos têm desempenho limitado em capturar padrões visuais complexos:

- 1) *SVM*: Acurácia: 0.78 F1 (Maligno): 0.53 F1 (Suspeito): 0.31
- 2) *Random Forest*: Acurácia: 0.70 Baixo desempenho em classes minoritárias (F1 \downarrow 0.06)
- 3) *MLP*: Acurácia: 0.75 Melhor que RF, porém ainda inferior à CNN.

B. Modelo CNN (ResNet50)

Resultados no conjunto de teste:

- Acurácia global: **0.86**
- Benigno: Precision 0.95, Recall 0.90, F1 0.92
- Maligno: Precision 0.75, Recall 0.72, F1 0.74
- Suspeito: Precision 0.61, Recall 0.84, F1 0.70

A Figura abaixo mostra a matriz de confusão:

VI. DISCUSSÃO

A CNN superou todos os modelos clássicos com margem significativa. A capacidade de extrair características diretamente das imagens é especialmente relevante em dados médicos, onde detalhes sutis são difíceis de capturar por técnicas manuais.

O alto desempenho na classe Maligno é crucial para aplicações clínicas. A classe Suspeito, apesar de menor representação, também apresentou recall elevado.

Desafios incluem:

- desbalanceamento do dataset,
- variação entre equipamentos de captura,
- necessidade de validação externa.




Fig. 1: Matriz de confusão do modelo ResNet50 no conjunto de teste.

VII. CONCLUSÃO

Este estudo demonstrou a superioridade das técnicas de Deep Learning — especialmente o uso de ResNet50 com *fine-tuning* — em relação aos modelos tradicionais para classificação de imagens dermatoscópicas.

Como trabalhos futuros, sugere-se:

- experimentos com datasets adicionais (ISIC, Fitzpatrick17k),
- métodos de interpretabilidade (Grad-CAM),
- avaliação clínica com profissionais dermatologistas.

REFERENCES

- [1] P. Tschandl, C. Rosendahl, and H. Kittler, "The HAM10000 Dataset: A Large Collection of Multi-Source Dermatoscopic Images of Common Pigmented Skin Lesions," 2018.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. CVPR*, 2016.
- [3] C. Cortes and V. Vapnik, "Support Vector Networks," *Machine Learning*, 1995.